

Écrêter au lieu d'amortir :
l'expression du clipping et l'algorithme d'entraînement
Famille B de l'expérience E16 (docs/reports/plan_floor_clip.md)

Septembre 2026

En bref

Les modes **ekfac** et **tekfac** divisent chaque coordonnée du pas, dans une base propre, par une courbure stockée à laquelle on ajoute une constante de sécurité λ . La famille B remplace cette addition par un *écrêtage* : on divise par la courbure seule, puis on plafonne chaque coordonnée à un seuil γ . Le seuil est toujours fixé *couche par couche*, parce que l'erreur d'échelle de la courbure stockée varie d'une couche à l'autre jusqu'à quatre ordres de grandeur. Trois façons de le fixer sont implémentées, parce qu'elles ne posent pas la même question :

- **quantile** : γ recalculé à chaque pas pour écrêter une proportion fixe q des coordonnées. C'est une normalisation du pas par couche autant qu'un écrêtage ;
- **ema** (bras principal) : le même seuil, corrigé par la taille du momentum rapportée à sa moyenne (corrigée du biais) sur environ 1 000 pas, pour que le pas suive de nouveau le momentum ;
- **fixe** : la médiane du seuil de la couche sur les 1 000 pas précédant le pas 2 000, puis gelée. C'est un écrêtage conditionnel, comme celui de Sophia.

C'est l'option `rescale_form="clip"` d'AdaFisherMulti, avec `clip_threshold` et `clip_fraction=q`, implémentée dans `src/adafisher_modes/approximations/_rescale_utils.py`.

1 Notations

Tout est écrit pour **ekfac**. Pour **tekfac**, il suffit de remplacer $Q_A \rightarrow Q_\Phi$, $Q_B \rightarrow Q_\Psi$ et $s^* \rightarrow \Theta$.

Pour une couche ℓ , on appelle *ligne* un couple (exemple, position) : une seule position pour une couche dense appliquée à un vecteur, T_ℓ positions pour une convolution (les positions de sortie) ou pour une couche appliquée à une séquence de T_ℓ jetons. Pour chaque ligne t :

- $\bar{h}_t$ est l'entrée de la couche, sous la forme que lui donne l'optimiseur :
 - couche dense ou convolution *avec* biais : l'entrée (le patch, pour une convolution), augmentée d'un 1 pour le biais ;
 - couche *sans* biais : l'entrée seule, sans le 1 ;
 - couche de normalisation (**LayerNorm**, **BatchNorm2d**) : $\bar{h}_t = (z_t, 1)$, où z_t est la moyenne sur les canaux de l'entrée *brute*, pas de l'activation normalisée (déviation

4.6 de `CLAUDE.md`). Les paramètres d'échelle et de décalage forment alors une matrice $C \times 2$;

- pour une couche de normalisation, $\hat{x}_t \in \mathbb{R}^C$ est l'activation normalisée de la ligne, recalculée avec les statistiques qu'utilise la couche : par jeton pour `LayerNorm` ; pour `BatchNorm2d`, celles du batch en entraînement et les statistiques courantes en évaluation. Le vrai gradient de la ligne par rapport à (échelle, décalage) est la matrice $C \times 2$ $[\delta_t \odot \hat{x}_t, \delta_t]$;
- δ_t est le gradient de la perte moyenne du batch par rapport à la sortie de la couche à cette ligne ;
- $A = \mathbb{E}[\bar{h}\bar{h}^\top]$ et $B = \mathbb{E}[\delta\delta^\top]$, moyennes sur les NT_ℓ lignes du batch, sont les deux facteurs de Kronecker, tenus en moyenne glissante ; Q_A et Q_B sont leurs vecteurs propres ;
- s^* , de la forme de la matrice des paramètres ($d_{\text{out}} \times d_{\text{in}}$, avec une colonne de plus pour le biais s'il existe), est la courbure stockée dans la base propre $Q_B \otimes Q_A$ (le « rééchelonnement » d'EKFAC) ;
- m est le momentum de la couche, poids et biais réunis dans une matrice de cette même forme, n son nombre de coordonnées, et $\hat{m}_t = m_t / (1 - \beta^{t+1})$ le momentum corrigé du biais.

Une conséquence des lignes : l'échelle de s^* dépend de la couche. Moyenner sur NT_ℓ lignes au lieu de N exemples divise la courbure stockée d'une couche partagée par un facteur de l'ordre de T_ℓ (`plan_exp_lot3.md` §5.2). Le surrogate des couches de normalisation ajoute une erreur de plus. Mesuré au pas 2000 avec ce surrogate, par rapport à la tête : de 1/422 à 1/7400 sur les convolutions de `cnn_gn_cifar`, de 1/251 à 1/5620 sur `vit_micro_cifar`, de 1/91 à 1/2724 sur `cct_2_3x2_cifar`. C'est pourquoi aucun seuil n'est partagé entre couches. L'option `norm_exact_rescaling`, activée dans tous les bras d'E16, supprime la seconde erreur (§5), pas la première.

On projette le momentum corrigé dans la base propre :

$$\widetilde{M} = Q_B^\top \hat{m} Q_A.$$

Toutes les opérations qui suivent sur $\widetilde{M}$ et s^* sont faites coordonnée par coordonnée.

2 Trois façons de diviser par la courbure

Dans chaque cas, la couche se déplace de $-\eta Q_B U Q_A^\top$, et seule la matrice U change :

forme	U_i	taux d'apprentissage
add (correctif E14, défaut)	$\frac{\widetilde{M}_i}{s_i^* + \lambda}$	$\eta = \text{cap} \cdot \lambda$
floor (famille A)	$\frac{\widetilde{M}_i}{\max(s_i^*, \lambda)}$	$\eta = \text{cap} \cdot \lambda$
clip (famille B)	voir (4)	η du benchmark

Pour `add` et `floor`, $\widetilde{M}$ est projeté depuis le momentum brut m , et la correction de biais est appliquée ensuite au pas, comme dans `AdaFisher` ; l'opérateur étant linéaire, cela revient au même. Dans ces deux formes, λ fixe à la fois le plancher de la courbure et, avec $\eta = \text{cap} \cdot \lambda$, la

taille maximale du pas. Dans la troisième, λ n'intervient plus du tout.

3 L'expression du clipping

3.1 L'opération d'écrêtage

Pour une couche, à un pas donné :

$$r_i = \frac{|\widetilde{M}_i|}{s_i^*} \quad \text{taille du pas } \textit{non amorti} \text{ de la coordonnée } i, \quad (1)$$

$$g = \kappa \text{ rms}(\widetilde{M}) = \kappa \left(\frac{1}{n} \sum_j \widetilde{M}_j^2 \right)^{1/2}, \quad \kappa = 10^{-3} \quad \text{garde}, \quad (2)$$

$$\mathcal{A} = \{ i : |\widetilde{M}_i| > g \}, \quad n_a = |\mathcal{A}| \quad \text{coordonnées actives}, \quad (3)$$

$$U_i = \begin{cases} \text{sign}(\widetilde{M}_i) \min\left(\frac{r_i}{\gamma}, 1\right) & i \in \mathcal{A}, \\ \frac{\widetilde{M}_i}{\max(\gamma s_i^*, g)} & i \notin \mathcal{A}. \end{cases} \quad (4)$$

- Une coordonnée active est *écrêtée* quand $r_i \geq \gamma$: $U_i = \pm 1$, elle bouge exactement de η_t . L'écrêtage est *défini* par ce test, sur le tenseur r même dont γ est tiré ; le nombre de coordonnées écrêtées est donc exact par construction (aux ex-æquo près).
- Une coordonnée active non écrêtée vaut $\widetilde{M}_i/(\gamma s_i^*)$: le pas de Newton non amorti, divisé par γ . Elle garde la forme que dicte la courbure.
- Une coordonnée inactive bouge d'au plus $|\widetilde{M}_i|/g < 1$.
- Pour une coordonnée active, $\text{clip}(x/(\gamma s), 1) = x/\max(\gamma s, |x|)$: l'écrêtage est un plancher sur la courbure, mais un plancher proportionnel au momentum lui-même ($|\widetilde{M}_i|/\gamma$), et non une constante λ .

Lien avec Sophia (Liu et al., arXiv :2305.14342). La mise à jour de Sophia est $\theta \leftarrow \theta - \eta \text{ clip}(m/(\rho h + \epsilon), 1)$. Le γ ci-dessus joue le rôle de ρ . Sophia fixe un seul ρ pour tout le réseau, ce qui a un sens chez elle parce que son estimation h a la bonne échelle dans toutes les couches (§2.3) ; ici ce n'est pas le cas. Sophia surveille la proportion de coordonnées non écrêtées (son `win_rate`, entre 0,1 et 0,5, soit une proportion écrêtée de 0,5 à 0,9).

3.2 La garde et les coordonnées actives

La proportion écrêtée q ne compte que les coordonnées actives. Ce choix a été imposé par une mesure. Dans la base propre, beaucoup de coordonnées sont nulles en arithmétique exacte : le gradient vit dans l'espace engendré par les entrées du batch, et A n'a que peu de directions observées. En float32, ces coordonnées valent du bruit d'arrondi. Mesuré sur un batch de 6 exemples : $|\widetilde{M}_i|$ descend jusqu'à 10^{-13} , et la médiane de r est entièrement fixée par ces coordonnées. Si on les comptait, le seuil tomberait dans le bruit et toutes les coordonnées réelles seraient écrêtées. Sans garde, une direction de courbure exactement nulle (les directions de la tête qui ajoutent une même constante à tous les logits) ferait un pas entier piloté par l'arrondi.

Le niveau $\kappa = 10^{-3}$ est un choix, pas un écart mesuré. Sur les vraies couches, des coordon-

nées réelles descendent jusqu'à $5 \cdot 10^{-6}$ rms et des lignes nulles montent jusqu'à $9,8 \cdot 10^{-4}$ rms. Tout verdict sur l'écrêtage est donc un verdict à $\kappa = 10^{-3}$.

3.3 Trois façons de fixer le seuil γ , toutes couche par couche

On note $\text{quant}_q(r)$ la c -ième plus grande valeur de $\{r_i : i \in \mathcal{A}\}$, avec $c = \max(\lfloor q n_a \rfloor, 1)$. Elle est calculée par un tri et une lecture d'indice sur le GPU, sans que n_a ne remonte à l'hôte.

Quantile : recalculé à chaque pas.

$$\gamma_t = \text{quant}_q(r_t).$$

Exactement c coordonnées actives sont écrêtées à chaque pas. Pour tous $a, b > 0$, $U(a\widetilde{M}, b s^*) = U(\widetilde{M}, s^*)$: aucune erreur d'échelle de la courbure stockée n'atteint le pas. Mais la taille du momentum non plus. La plus grande coordonnée de chaque couche bouge de η_t à chaque pas, même quand le gradient s'éteint. C'est donc une *normalisation du pas par couche* avec un écrêtage de sa forme. Cette règle sert de contrôle.

EMA : le pas suit de nouveau le momentum. Avec $\mu_t = \text{rms}(\widetilde{M}_t)$ et $w = 1/H$, $H = 1\,000$ pas :

$$\nu_t = (1 - w) \nu_{t-1} + w \log \mu_t, \quad d_t = (1 - w) d_{t-1} + w, \quad \log \bar{\mu}_t = \frac{\nu_t}{d_t}, \quad \gamma_t = \text{quant}_q(r_t) \cdot \frac{\bar{\mu}_t}{\mu_t},$$

avec $\nu_0 = d_0 = 0$: c'est la moyenne glissante corrigée du biais d'Adam, appliquée à $\log \mu$. Un pas de momentum nul ne porte pas de taille et n'est pas compté.

- Si le momentum a sa taille habituelle ($\mu_t = \bar{\mu}_t$), c'est exactement la règle quantile.
- S'il est a fois plus petit que sur les $\sim H$ derniers pas, les coordonnées non écrêtées sont a fois plus petites et moins de coordonnées sont écrêtées. Un pic est écrêté plus fort.
- L'échelle de la courbure reste absorbée à chaque pas : seule la taille du momentum est retardée.
- La moyenne porte sur μ et non sur γ , parce que γ contient aussi l'échelle de s^* , qui saute à chaque mise à jour des facteurs (s^* est à 92 % un seul minibatch).
- **Pourquoi la correction de biais.** Le premier momentum corrigé est un seul gradient, mesuré 4,4 à 5 fois plus grand en moyenne quadratique que le momentum une fois installé. Une moyenne initialisée avec lui restait décalée de plus de 10 % pendant 12 à 18 % d'un entraînement.

Fixe : un écrêtage conditionnel.

$$\gamma_t = \begin{cases} \text{quant}_q(r_t) & t < t_{\text{cal}}, \\ \text{med}\{\text{quant}_q(r_\tau) : t_{\text{cal}} - W \leq \tau < t_{\text{cal}}\} \text{ gelée} & t \geq t_{\text{cal}}, \end{cases}$$

avec $t_{\text{cal}} = 2\,000$ et $W = 1\,000$ (médiane inférieure). Après la calibration, l'écrêtage n'agit que là où le pas non amorti dépasse le plafond, et en dessous le pas est proportionnel au momentum.

- **Une médiane sur une fenêtre**, parce que le quantile d’un seul pas est un tirage : il variait d’un facteur 3,6 d’une mise à jour des facteurs à l’autre.
- **Couche par couche**, à cause de l’erreur d’échelle propre à chaque couche. Cela rend aussi la bascule continue : la valeur gelée est celle que la couche utilisait. Mesuré sur de vrais réseaux : la taille du pas change d’un facteur 0,92 à 1,04 à la bascule.
- t_{cal} et le début de la fenêtre sont au-delà des $10 \cdot T_{\text{Cov}} = 1\,000$ pas nécessaires à l’effacement de la graine identité (époque 2 sur 15 à batch 32).
- Après la calibration, la proportion écrêtée dérive librement ; elle est journalisée. C’est le diagnostic de Sophia.

3.4 Propriétés communes

1. **Pas borné.** $|U_i| \leq 1$: chaque coordonnée de la base propre bouge d’au plus η_t , quelle que soit la courbure.
2. **Momentum corrigé du biais.** L’écrtage compare le momentum à un seuil, ce qui n’est pas une opération linéaire. Il reçoit donc $\hat{m}$, et le pas est appliqué sans nouvelle division par $1 - \beta^{t+1}$. Pour la règle quantile, c’est sans effet (invariance d’échelle).
3. **Les deux limites.** Quand $q \rightarrow 1$, presque tout est écrêté : $U \approx \text{sign}(\widetilde{M})$, une descente de signe dans la base propre. Quand $q \rightarrow 0$, $U \approx \widetilde{M}/(\gamma s^*)$: le pas EKFAC non amorti, dont la plus grande coordonnée vaut 1 (au moment de la calibration, pour la règle fixe).

4 L’algorithme d’entraînement

Constantes livrées : moyenne glissante $X \leftarrow \rho_{\text{old}}X + \rho_{\text{new}}X_{\text{inst}}$ avec $(\rho_{\text{old}}, \rho_{\text{new}}) = (0,08, 0,008)$; $T_{\text{Cov}} = T_{\text{eig}} = 100$; $\beta = 0,9$. Le calcul de la base propre se fait dans le hook backward, avant de projeter le gradient (`eig_before_rescale=True`), pour que s^* soit mesuré dans la base qu’utilise ensuite le pas. Dans l’algorithme, $R_\ell = N T_\ell$ est le nombre de lignes de la couche ℓ dans un batch.

Algorithme 1 EKFAc avec écrêtage (famille B), T pas d'entraînement

Entrées : paramètres θ ; taux de base η et calendrier cosinus η_t ; $\beta = 0,9$; proportion écrêtée $q \in (0, 1)$; $\kappa = 10^{-3}$; règle $\in \{\text{quantile, ema, fixe}\}$; $H = 1000$; $t_{\text{cal}} = 2000$; $W = 1000$; weight decay w_d (couplé ou découplé)

- 1: pour chaque couche hookée ℓ : $A_\ell \leftarrow I$, $B_\ell \leftarrow I$, $m_\ell \leftarrow 0$, $\nu_\ell \leftarrow 0$, $d_\ell \leftarrow 0$, $\mathcal{W}_\ell \leftarrow \emptyset$, $\gamma_\ell^{\text{fixe}} \leftarrow$ non défini
- 2: **pour** $t = 0, \dots, T - 1$ **faire**
- 3: tirer un batch de N exemples; forward
- 4: **si** $t \bmod T_{\text{Cov}} = 0$ **alors**
- 5: chaque couche ℓ garde ses R_ℓ lignes $\bar{h}_{\ell,r}$ ▷ entrées, forme de §1
- 6: et, sous **norm_exact_rescaling**, chaque couche de normalisation ses $\hat{x}_{\ell,r}$
- 7: $L \leftarrow \frac{1}{N} \sum_n \ell(f_\theta(x_n), y_n)$; backward
- 8: **si** $t \bmod T_{\text{Cov}} = 0$ **alors** ▷ hooks backward, pour chaque couche ℓ
- 9: $A_\ell \leftarrow \rho_{\text{old}} A_\ell + \rho_{\text{new}} \frac{1}{R_\ell} \sum_r \bar{h}_{\ell,r} \bar{h}_{\ell,r}^\top$
- 10: $B_\ell \leftarrow \rho_{\text{old}} B_\ell + \rho_{\text{new}} \frac{1}{R_\ell} \sum_r \delta_{\ell,r} \delta_{\ell,r}^\top$
- 11: **si** $t \bmod T_{\text{eig}} = 0$ **alors**
- 12: $Q_{A,\ell} \leftarrow \text{vecp}(A_\ell + \varepsilon I)$, $Q_{B,\ell} \leftarrow \text{vecp}(B_\ell + \varepsilon I)$ ▷ $\varepsilon = 10^{-6} \overline{\text{diag}}$
- 13: **si** premier calcul **alors** $s_\ell^* \leftarrow \mathbf{1}$
- 14: **si** ℓ est une couche de normalisation **et** **norm_exact_rescaling** **alors**
- 15: $G_\ell \leftarrow \frac{1}{R_\ell} \sum_r (Q_{B,\ell}^\top [\delta_{\ell,r} \odot \hat{x}_{\ell,r}, \delta_{\ell,r}] Q_{A,\ell})^{\odot 2}$ ▷ vrai gradient de la ligne
- 16: **sinon**
- 17: $G_\ell \leftarrow \frac{1}{R_\ell} \sum_r (Q_{B,\ell}^\top \delta_{\ell,r})^{\odot 2} (Q_{A,\ell}^\top \bar{h}_{\ell,r})^{\odot 2 \top}$ ▷ carrés coordonnée par coordonnée
- 18: $s_\ell^* \leftarrow \rho_{\text{old}} s_\ell^* + \rho_{\text{new}} G_\ell$
- 19: **pour** chaque couche hookée ℓ , poids et biais ensemble **faire**
- 20: $g_\ell \leftarrow \nabla_{[W_\ell, b_\ell]} L$ (+ $w_d [W_\ell, b_\ell]$ si weight decay couplé)
- 21: $m_\ell \leftarrow \beta m_\ell + (1 - \beta) g_\ell$; $\hat{m}_\ell \leftarrow m_\ell / (1 - \beta^{t+1})$
- 22: $\widetilde{M} \leftarrow Q_{B,\ell}^\top \hat{m}_\ell Q_{A,\ell}$; $r \leftarrow |\widetilde{M}| \odot s_\ell^*$; $g \leftarrow \kappa \text{rms}(\widetilde{M})$; $\mathcal{A} \leftarrow \{i : |\widetilde{M}_i| > g\}$
- 23: **si** règle = fixe **et** $\gamma_\ell^{\text{fixe}}$ défini **alors**
- 24: $\gamma \leftarrow \gamma_\ell^{\text{fixe}}$
- 25: **sinon**
- 26: $\gamma \leftarrow \text{quant}_q(r_{\mathcal{A}})$ ▷ c -ième plus grande, $c = \max(\lfloor q |\mathcal{A}| \rfloor, 1)$
- 27: **si** règle = ema **et** $\text{rms}(\widetilde{M}) > 0$ **alors**
- 28: $\mu \leftarrow \text{rms}(\widetilde{M})$; $\nu_\ell \leftarrow (1 - \frac{1}{H}) \nu_\ell + \frac{1}{H} \log \mu$; $d_\ell \leftarrow (1 - \frac{1}{H}) d_\ell + \frac{1}{H}$
- 29: $\gamma \leftarrow \gamma \cdot \exp(\nu_\ell / d_\ell) / \mu$
- 30: **si** règle = fixe **et** $t_{\text{cal}} - W \leq t < t_{\text{cal}}$ **alors** $\mathcal{W}_\ell \leftarrow \mathcal{W}_\ell \cup \{\gamma\}$
- 31: **si** règle = fixe **et** $t \geq t_{\text{cal}}$ **alors**
- 32: $\gamma_\ell^{\text{fixe}} \leftarrow \text{med}(\mathcal{W}_\ell)$ (ou γ si $\mathcal{W}_\ell = \emptyset$); $\gamma \leftarrow \gamma_\ell^{\text{fixe}}$ ▷ gelé
- 33: $U_i \leftarrow \text{sign}(\widetilde{M}_i) \min(r_i / \gamma, 1)$ si $i \in \mathcal{A}$, sinon $U_i \leftarrow \widetilde{M}_i / \max(\gamma s_{\ell,i}^*, g)$ ▷ éq. (4)
- 34: $D_\ell \leftarrow Q_{B,\ell} U Q_{A,\ell}^\top$
- 35: **si** weight decay découplé **alors** $[W_\ell, b_\ell] \leftarrow (1 - \eta_t w_d) [W_\ell, b_\ell]$
- 36: $[W_\ell, b_\ell] \leftarrow [W_\ell, b_\ell] - \eta_t D_\ell$ ▷ sans correction de biais
- 37: autres paramètres : momentum simple avec correction de biais ▷ gelés dans E16
- 38: $\eta_{t+1} \leftarrow$ calendrier cosinus

5 Remarques

- **Ce que fait la courbure ici.** Elle fixe la *forme* du pas dans les trois règles. Sa taille est bornée par η_t coordonnée par coordonnée. Avec la règle quantile, la taille du pas ne dépend plus que de η_t ; avec les règles EMA et fixe, elle suit aussi le momentum.
- **Ce que chaque comparaison isole dans E16.** EMA contre quantile : le même écrêtage, avec ou sans normalisation à chaque pas. Fixe contre **add** : un plancher proportionnel au momentum contre un plancher constant, l'énoncé le plus net de la famille B. Fixe contre EMA : un seuil gelé contre un seuil qui suit le momentum, tous deux par couche.
- **Couches de normalisation.** Sans option, leur s^* est estimé depuis $\bar{h}_t = (z_t, 1)$, construit sur la moyenne des canaux de l'entrée brute. Ce n'est donc pas le second moment du vrai gradient de la ligne, $[\delta_t \odot \hat{x}_t, \delta_t]$. Mesuré au pas 300, la colonne qui porte l'échelle est 295 à 989 fois trop petite sur les LayerNorm de `vit_micro_cifar`, 80 à 106 fois sur celles de `cct_2_3x2_cifar` ; la colonne de décalage est juste ($\times 0,96$ à $1,03$). L'écrêtage l'exposait à $q \leq 0,3$, en freinant les pas de décalage d'un facteur 3 à 117. L'option `norm_exact_rescaling` corrige cela : s^* est la moyenne des carrés du vrai gradient de chaque ligne, projeté dans la même base (algorithme 1). Le lemme 1 d'EKFAC en fait la diagonale optimale dans cette base, quelle que soit la base. La base elle-même vient toujours de A , donc du surrogate. L'option est activée dans tous les bras d'E16, y compris le correctif E14 qui y est relancé.
- **Convolutions.** m est le poids remis en forme $C_{\text{out}} \times C_{\text{in}} k_h k_w$ (plus une colonne de biais s'il existe). Avec SUA, $\widetilde{M}$ a la forme $k_h k_w \times C_{\text{out}} \times C_{\text{in}}$ (même remarque), et γ est calculé sur l'ensemble des positions du noyau de la couche.
- **Coût.** Par couche et par pas, en plus d'EKFAC : un tri sur n valeurs, une lecture d'indice et quelques opérations coordonnée par coordonnée. Pas de synchronisation avec l'hôte, pas de décomposition supplémentaire. Les statistiques ne sont calculées que lorsqu'on les lit.
- **Ce qui est comparé dans E16.** Les trois règles (7 valeurs de q chacune), la famille A ($\max(s^*, \lambda)$, 5 valeurs de λ) et le correctif E14 ($s^* + \lambda$, les mêmes 5 valeurs, relancé dans E16), sur `cnn_gn_cifar`, `vit_micro_cifar` et `cct_2_3x2_cifar`, avec `ekfac` et `tekf` et 5 graines. Les règles de décision sont pré-enregistrées dans `docs/reports/plan_lambda_dominance.md`, section E16.